

Trabajo Final de Procesamiento de imágenes en Python

Instituto: ISFT N° 190

Carrera: Tec. en Ciencia de Datos e Inteligencia Artificial

Alumna: Paola Fernanda Dueña

Tema: Detección de fracturas óseas en radiografías

Trabajo Final de Procesamiento de Imágenes en Python

ISFT N° 190 - Tecnicatura en Ciencia de Datos e Inteligencia Artificial Integrante:

Paola Fernanda Dueña

Tema: Detección automática de fracturas óseas en radiografías

Repositorio: <https://github.com/PaoRioColorado/Deteccion-de-fracturas-Rayos-X/blob/main/README.md>

Link al video: <https://drive.google.com/file/d/1vt3VEURmBgkW5OmbXE1kjTuPi-Zn-Dw2/view?usp=sharing>

INTRODUCCIÓN

Las radiografías constituyen una de las herramientas más utilizadas en el ámbito médico para el diagnóstico de fracturas óseas. A pesar de su uso extendido, la interpretación de este tipo de imágenes puede resultar compleja, especialmente cuando las fracturas son pequeñas, presentan bajo contraste o se encuentran en zonas anatómicas de difícil visualización.

El análisis manual de radiografías depende fuertemente de la experiencia del profesional y puede verse afectado por factores humanos como el cansancio o la sobrecarga de trabajo. En este contexto, el procesamiento digital de imágenes surge como una herramienta de apoyo que permite mejorar la visualización y asistir en la detección de patrones relevantes.

El objetivo de este trabajo es desarrollar un **pipeline reproducible de procesamiento de imágenes** orientado a la **detección automática de fracturas óseas en radiografías**, mediante la localización de regiones de interés utilizando *bounding boxes*. El sistema tiene fines educativos y demostrativos, y no pretende sustituir sistemas clínicos reales.

MARCO TEÓRICO Y CONCEPTOS FUNDAMENTALES

La **detección de objetos** es una tarea del procesamiento de imágenes y la visión por computadora cuyo objetivo es localizar y delimitar regiones de interés dentro de una imagen. A diferencia de la clasificación, donde se asigna una etiqueta global a toda la imagen, la detección busca identificar **dónde** se encuentra el objeto de interés.

En este trabajo, la localización de fracturas se representa mediante **bounding boxes**. Una *bounding box* es un rectángulo definido por coordenadas dentro de la imagen que encierra la región donde se encuentra el objeto de interés, en este caso una fractura ósea. Este enfoque es ampliamente utilizado en tareas de detección por su simplicidad y claridad visual.

El término **ground truth** hace referencia a las anotaciones reales del dataset, consideradas como la referencia correcta contra la cual se comparan las detecciones generadas por el sistema.

Para evaluar la calidad de una detección se utilizan métricas específicas. La métrica **Intersection over Union (IoU)** mide el grado de superposición entre la *bounding box* predicha y la *bounding box* real. Por su parte, el **F1-score** combina dos métricas fundamentales:

- **Precisión (precision):** proporción de detecciones correctas sobre el total de detecciones realizadas.
- **Recall:** proporción de fracturas reales correctamente detectadas.

DATASET Y CONSIDERACIONES ÉTICAS

El proyecto utiliza el **FracAtlas Original Dataset**, disponible públicamente en la plataforma Kaggle. Este dataset contiene radiografías óseas anotadas con *bounding boxes* que indican la localización de fracturas.

Las imágenes se organizan en subconjuntos de **entrenamiento (train)**, **validación (validation)** y **prueba (test)**, siguiendo buenas prácticas que permiten evaluar el sistema sin introducir sesgos por reutilización de datos.

El uso del dataset se realiza exclusivamente con fines académicos. Las imágenes no contienen información personal identificable y se respeta la licencia de uso correspondiente. No se trabaja con datos sensibles ni con información clínica privada.

Entre las principales limitaciones del dataset se encuentran la variabilidad en la calidad de imagen, diferencias de iluminación y contraste, fracturas sutiles difíciles de identificar y un posible desbalance entre imágenes con y sin fractura.

El dataset FracAtlas Original se encuentra disponible públicamente en Kaggle, en el siguiente enlace: <https://www.kaggle.com/datasets/medali1992/fractatlas>

METODOLOGÍA Y PIPELINE PROPUESTO

El sistema desarrollado sigue un **pipeline claro y reproducible**, compuesto por las siguientes etapas: lectura de la imagen, preprocesado, simulación de detección, cálculo de métricas y visualización de resultados.

En la etapa de preprocesado se realizan operaciones básicas como el escalado de la imagen y ajustes de visualización, con el objetivo de facilitar la interpretación visual.

A partir de las anotaciones del *ground truth* se implementan dos enfoques. El primero corresponde a un **baseline** simple, que introduce ruido, desplazamientos aleatorios en las *bounding boxes* y una mayor cantidad de **falsos positivos**, es decir, detecciones incorrectas donde no existe una fractura real.

El segundo enfoque corresponde a un **pipeline mejorado**, donde se reduce el ruido y se ajusta mejor la posición de las *bounding boxes*, logrando una detección más precisa. La comparación entre ambos enfoques permite analizar el impacto de mejoras graduales dentro del flujo de procesamiento.

Cabe destacar que el pipeline desarrollado tiene un carácter demostrativo y reproducible, y busca ilustrar conceptos fundamentales de detección y evaluación más que optimizar el rendimiento para un entorno clínico real.

■ EXPERIMENTOS Y MÉTRICAS DE EVALUACIÓN

Los experimentos se diseñan para comparar de manera objetiva el baseline con el pipeline mejorado. Ambos métodos se evalúan utilizando las mismas imágenes y bajo los mismos umbrales de decisión.

La métrica **IoU** se utiliza para medir la precisión espacial de las detecciones, mientras que el **F1-score** permite evaluar el equilibrio entre detecciones correctas y errores. Estas métricas son ampliamente utilizadas en tareas de detección de objetos y resultan adecuadas para el problema abordado.

El umbral de decisión basado en IoU puede ajustarse dinámicamente para analizar distintos niveles de exigencia en la detección, permitiendo observar cómo varía el desempeño del sistema frente a criterios más o menos estrictos de superposición entre las bounding boxes predichas y las reales.

■ RESULTADOS

Los resultados obtenidos muestran que el pipeline mejorado alcanza valores superiores de **IoU promedio** y **F1-score** en comparación con el baseline. Desde el punto de vista visual, las *bounding boxes* del pipeline mejorado presentan una mejor alineación con las fracturas reales y una menor cantidad de detecciones erróneas.

Sin embargo, se observa que en imágenes con estructuras óseas superpuestas o con fracturas de pequeño tamaño, la diferencia entre ambos enfoques se reduce, evidenciando la dificultad del problema en escenarios más complejos.

Estos resultados refuerzan la utilidad del pipeline propuesto como herramienta didáctica para el análisis comparativo de estrategias de detección.

DISCUSIÓN Y ANÁLISIS CRÍTICO

A pesar de la mejora observada, el sistema presenta fallos en casos complejos, como fracturas pequeñas o imágenes con bajo contraste. Asimismo, la calidad de las anotaciones del ground truth influye directamente en el desempeño del sistema, ya que errores o imprecisiones en las etiquetas afectan la evaluación de las detecciones.

Por otra parte, la simulación de detecciones, si bien resulta útil con fines educativos, no contempla características propias de modelos entrenados, como la capacidad de generalización ante imágenes no vistas o la adaptación a variaciones anatómicas más complejas. En este sentido, los resultados obtenidos deben interpretarse como una aproximación didáctica al problema de detección y no como una solución aplicable a entornos clínicos reales.

Estos resultados ponen de manifiesto las limitaciones inherentes a un enfoque simulado y resaltan la importancia de contar con datos de alta calidad y metodologías más avanzadas para tareas de detección automática en imágenes médicas.

LIMITACIONES Y TRABAJO A FUTURO

La principal limitación del trabajo es que la detección implementada es **simulada** y no corresponde a un modelo entrenado real. No se realiza validación clínica ni se emplean técnicas de aprendizaje profundo.

Como trabajo futuro se propone la integración de detectores basados en **deep learning**, como redes neuronales convolucionales, la ampliación del dataset y la incorporación de técnicas de validación más avanzadas.

CONCLUSIONES

En este trabajo se presentó un pipeline reproducible de procesamiento de imágenes aplicado a la detección de fracturas óseas en radiografías. La comparación entre un baseline y un pipeline mejorado permitió comprender la importancia de la evaluación objetiva y del diseño cuidadoso del flujo de procesamiento.

El proyecto cumple su objetivo educativo y proporciona una base sólida para futuros desarrollos más avanzados en el área de visión por computadora aplicada a imágenes médicas.

CONSIDERACIONES ÉTICAS

Este sistema tiene fines exclusivamente educativos y no debe utilizarse como herramienta diagnóstica. El uso de las imágenes respeta licencias académicas y no involucra datos personales identificables.